Predicción de enfermedad cardíaca con Regresión Logística

Hecho por: Santiago Chacon y Alejandro Mafla

Materia: Teoria de la Computacion II

Universidad La Salle

Link del Repositorio:
https://github.com/notalejandromafla/proyectoFinal_prediccionCardiaca/tree/develop

Contenido

1. Introducción 3
2. Selección del modelo 3
3. Descripción del dataset 3
   Exploración y preparación 5
4. Métricas de evaluación 5
5. Matriz de confusión 6
6. Análisis ético 7
   6.1 Sesgos 7
   6.2 Riesgos 8
   6.3 Limitaciones 8
   6.4 Consideraciones éticas 8
7. Conclusiones técnicas 9
8. Recomendaciones de mejora 9
9. Referencias 10

1. Introducción

Las enfermedades cardiovasculares son una de las principales causas de muerte en el mundo, y detectarlas a tiempo cambia mucho el pronóstico de un paciente. Por eso nos interesó ver hasta qué punto un modelo sencillo de Machine Learning puede ayudar a identificar pacientes con enfermedad cardíaca a partir de datos clínicos básicos.

En este proyecto entrenamos un modelo de Regresión Logística con el dataset Heart Disease de UCI, medimos su desempeño con métricas de clasificación y analizamos sus implicaciones éticas, en especial si el modelo funciona igual de bien para hombres y mujeres. Desde el inicio lo planteamos como una herramienta de apoyo: no busca reemplazar el criterio de un médico.

Todo el código, los notebooks y la documentación técnica (arquitectura, decisiones de diseño y riesgos) están en el repositorio del proyecto. Este informe recoge el desarrollo de la actividad y nuestras conclusiones.

2. Selección del modelo

Elegimos la Regresión Logística. El problema es de clasificación binaria (ósea, si el paciente tiene o no tiene enfermedad cardíaca), y este modelo está pensado justamente para eso: estima la probabilidad de que un paciente pertenezca a la clase "enfermo" y, con un umbral de 0.5, la convierte en una predicción.

Tuvimos en cuenta tres razones:

- El tamaño de los datos: Después de la limpieza quedan 297 pacientes. Con tan pocos datos, un modelo simple tiene menos riesgo de sobreajustarse que uno más complejo.
- La interpretabilidad: Cada variable recibe un coeficiente que indica cuánto pesa en la predicción y en qué dirección. En salud esto importa mucho, porque un médico necesita entender por qué el modelo dice lo que dice.
- Es un buen punto de partida: Si un modelo lineal funciona razonablemente bien, sirve de base para comparar alternativas más complejas en el futuro.

El modelo va dentro de un *Pipeline* junto con un StandardScaler, que pone todas las variables en una escala comparable. Así el escalado se ajusta solo con los datos de entrenamiento y no hay fuga de información hacia el conjunto de prueba.

Para saber si el modelo realmente aprende algo, lo comparamos con un **modelo de referencia** (DummyClassifier) que siempre predice la clase más frecuente, es decir, que todos los pacientes están sanos.

3. Descripción del dataset

Usamos el dataset **Heart Disease** del repositorio UCI Machine Learning, en su versión de Cleveland. Los datos se recolectaron en la Cleveland Clinic Foundation, en Estados Unidos, y se publicaron en 1988. Es uno de los datasets más usados para aprender clasificación en el área de salud.

Tiene **303 pacientes** y **13 variables** clínicas y demográficas. La variable objetivo, `target`, indica si el paciente tiene enfermedad cardíaca (1) o no (0). En el dataset original esta variable iba de 0 a 4 según la gravedad; la convertimos en binaria para tratar el problema como sí o no.

Variable	Descripción	Tipo
age	Edad en años	Numérica
sex	Sexo (1 = hombre, 0 = mujer)	Categórica
cp	Tipo de dolor de pecho (1 a 4)	Categórica
trestbps	Presión arterial en reposo (mm Hg)	Numérica
chol	Colesterol sérico (mg/dl)	Numérica
fbs	Azúcar en sangre en ayunas mayor a 120 mg/dl (1 = sí, 0 = no)	Categórica
restecg	Resultado del electrocardiograma en reposo (0 a 2)	Categórica
thalach	Frecuencia cardíaca máxima alcanzada	Numérica
exang	Angina inducida por ejercicio (1 = sí, 0 = no)	Categórica
oldpeak	Depresión del segmento ST inducida por ejercicio	Numérica
slope	Pendiente del segmento ST en el pico del ejercicio (1 a 3)	Categórica
ca	Número de vasos principales coloreados por fluoroscopía (0 a 3)	Numérica
thal	Talasemia (3 = normal, 6 = defecto fijo, 7 = defecto reversible)	Categórica
target	1 = tiene enfermedad cardíaca, 0 = no	Objetivo

Así se ven los primeros cinco registros:

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
63	1	1	145	233	1	2	150	0	2.3	3	0	6	0
67	1	4	160	286	0	2	108	1	1.5	2	3	3	1
67	1	4	120	229	0	2	129	1	2.6	2	2	7	1
37	1	3	130	250	0	0	187	0	3.5	3	0	3	0
41	0	2	130	204	0	2	172	0	1.4	1	0	3	0

Exploración y preparación

En la exploración encontramos varias cosas importantes:

- Hay **6 registros con valores faltantes** (4 en `ca` y 2 en `thal`). Como son pocos, los eliminamos en lugar de inventarles un valor, y quedaron 297 pacientes.
- Las clases están bastante equilibradas: 164 pacientes sanos y 139 enfermos.
- La edad va de 29 a 77 años, con un promedio de 54.
- **El dataset tiene muchos más hombres que mujeres:** 206 hombres (68 %) y 97 mujeres (32 %). Además, la enfermedad es mucho más frecuente en los hombres: la tiene el 55 % de ellos frente al 26 % de las mujeres. Esto es clave para el análisis ético.

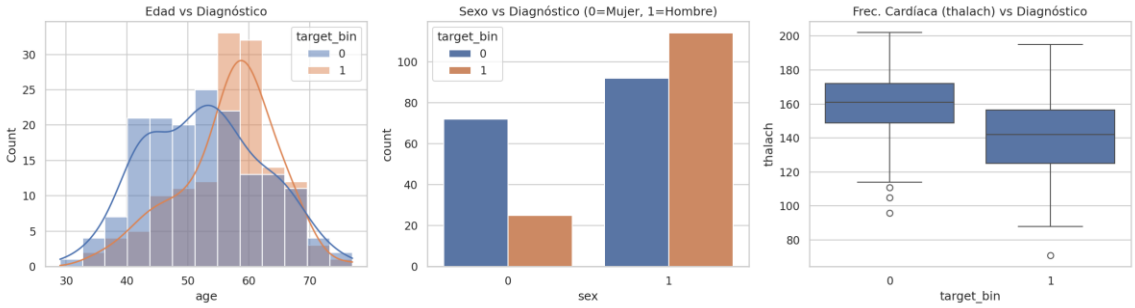


Figura 1. Distribución de la edad, del sexo y de la frecuencia cardíaca máxima según el diagnóstico (0 = sano, 1 = enfermo).

Finalmente, dividimos los datos en **80 % para entrenamiento (237 pacientes) y 20 % para prueba (60 pacientes)** de forma estratificada, para que ambos conjuntos tuvieran la misma proporción de enfermos (46 %).

4. Métricas de evaluación

Evaluamos los dos modelos con los **60 pacientes del conjunto de prueba**, que no se usaron durante el entrenamiento. Estos fueron los resultados:

Modelo	Accuracy	Precision	Recall	F1-Score
Referencia (DummyClassifier)	0.533	0.000	0.000	0.000
Regresión Logística	0.833	0.846	0.786	0.815

Lo que significa cada una:

- **Accuracy (0.833):** el modelo acertó en 50 de los 60 pacientes. Es la medida más intuitiva, pero por sí sola no dice qué tipo de errores comete.
- **Precision (0.846):** de los 26 pacientes que el modelo marcó como enfermos, 22 realmente lo estaban. Cuando el modelo da una alerta, casi siempre tiene razón.
- **Recall (0.786):** de los 28 pacientes que sí estaban enfermos, el modelo detectó 22. Dicho de otra forma, se le escaparon 6.
- **F1-Score (0.815):** combina Precision y Recall en un solo número. Un valor alto indica que el modelo no sacrifica mucho una métrica para mejorar la otra.

Para este problema, la métrica más importante es el Recall. No es lo mismo equivocarse en una dirección que en otra: si el modelo le dice a un paciente sano que podría estar enfermo, lo peor que pasa es que le hagan exámenes adicionales; pero si le dice a un paciente enfermo que está sano, podría quedarse sin tratamiento. Por eso nos preocupa más que el Recall no sea más alto que cualquiera de las otras métricas.

Comparación con el modelo de referencia. El modelo de referencia acierta el 53 % de las veces sin aprender nada, solo porque hay un poco más de pacientes sanos que enfermos. Sin embargo, nunca detecta a un enfermo (Recall de 0). La Regresión Logística lo supera por 30 puntos de Accuracy y en todas las demás métricas, lo que confirma que sí aprendió patrones reales de los datos.

Antes de evaluar definimos unos criterios de aceptación. El modelo cumple el de F1-Score mayor o igual a 0.75 y el de superar al modelo de referencia, pero **no cumple el de Recall mayor o igual a 0.80**, aunque queda cerca (0.786).

5. Matriz de confusión

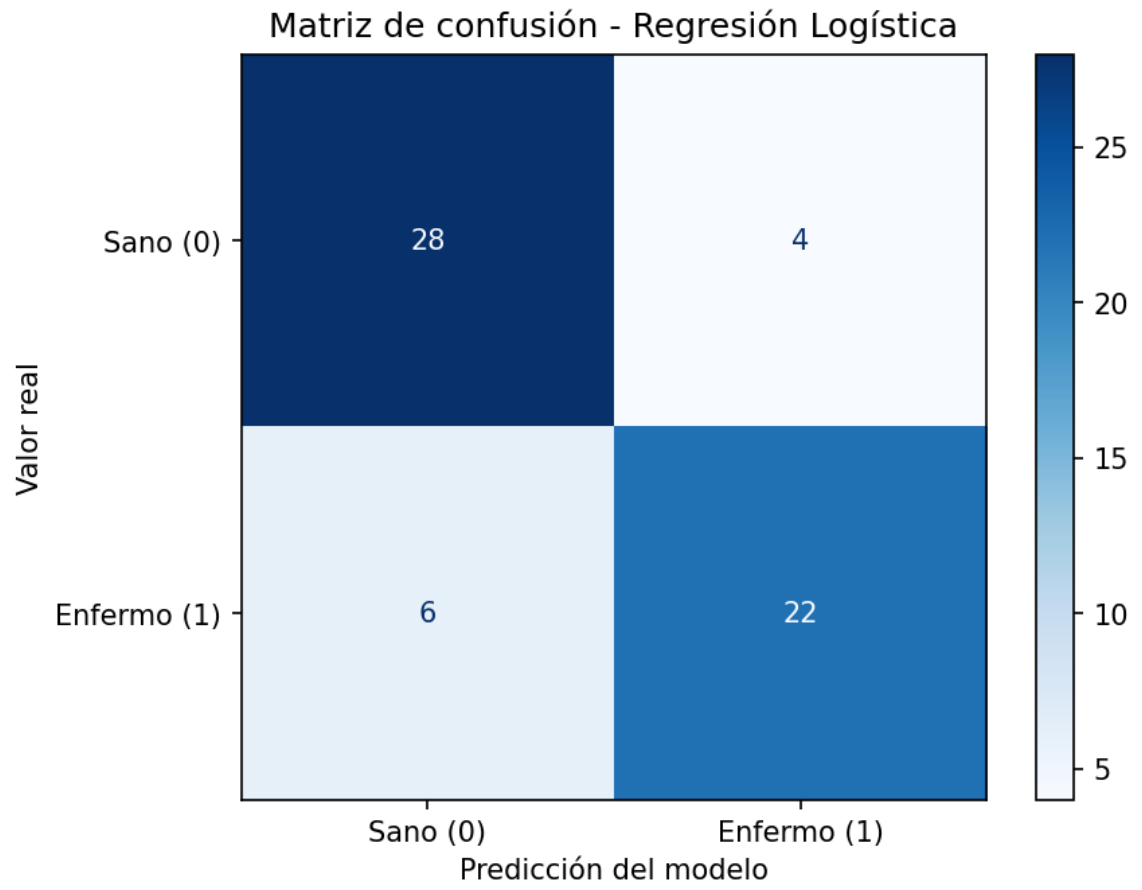


Figura 2. Matriz de confusión del modelo sobre los 60 pacientes de prueba. Las filas son el valor real y las columnas la predicción del modelo.

La matriz muestra en detalle en qué acierta y en qué se equivoca el modelo:

- **Verdaderos positivos (22):** pacientes enfermos que el modelo identificó correctamente como enfermos.
- **Verdaderos negativos (28):** pacientes sanos que el modelo identificó correctamente como sanos.
- **Falsos positivos (4):** pacientes sanos que el modelo marcó como enfermos. Es una falsa alarma: generaría preocupación y exámenes que no hacían falta.
- **Falsos negativos (6):** pacientes enfermos que el modelo marcó como sanos. Es el error más grave, porque son personas que podrían no recibir atención a tiempo.

El modelo comete menos falsos positivos (4) que falsos negativos (6). Es decir, tiende a ser algo "conservador" para dar la alerta, cuando en un contexto médico preferiríamos lo contrario: aceptar algunas falsas alarmas más a cambio de que se escapen menos enfermos.

6. Análisis ético

Un modelo puede tener buenas métricas generales y aun así tratar de forma desigual a ciertos grupos. Como este modelo trabaja con datos de salud, revisamos sus sesgos, riesgos y limitaciones, y las consideraciones éticas que tendría usarlo.

6.1 Sesgos

El dataset tiene una fuerte desproporción por sexo: 68 % hombres y 32 % mujeres. Además, la enfermedad aparece en el 55 % de los hombres pero solo en el 26 % de las mujeres. Esto quiere decir que el modelo vio muchos más ejemplos de hombres enfermos que de mujeres enfermas, y por lo tanto aprendió mejor cómo se presenta la enfermedad en ellos.

Sesgo en el modelo. Para comprobarlo, calculamos las métricas por separado para hombres y mujeres en el conjunto de prueba:

Grupo	Pacientes	Enfermos reales	Accuracy	Precision	Recall
Mujeres	19	3	0.947	1.000	0.667
Hombres	41	25	0.780	0.833	0.800

A primera vista, el modelo parece funcionar mejor con las mujeres, porque su Accuracy es más alto. Pero eso pasa solo porque la mayoría de las mujeres de la prueba están sanas y el modelo acierta fácilmente con ellas. Lo que de verdad importa es el Recall: el modelo detectó al 80 % de los hombres enfermos, pero solo al 67 % de las mujeres enfermas (2 de 3). La diferencia es de 0.133, mayor al límite de 0.10 que fijamos como criterio de equidad, así que el modelo no cumple ese criterio.

Hay que leer este resultado con cuidado: con solo 3 mujeres enfermas en la prueba, un solo caso cambia mucho el porcentaje, así que no es una conclusión firme. Aun así, es una señal de alerta coherente con lo que vimos en los datos.

El sexo como variable del modelo. Al revisar los coeficientes del modelo, sex resultó ser la cuarta variable que más influye en la predicción (0.48), después de ca, thal y cp. Es decir, el modelo usa

directamente el sexo del paciente para decidir, y le asigna a ser hombre un mayor riesgo. Esto refleja la tendencia de los datos, pero también puede reforzar la idea de que la enfermedad cardíaca "es cosa de hombres", cuando en la práctica se sabe que en las mujeres a veces se presenta con síntomas distintos y tiende a diagnosticarse menos.

6.2 Riesgos

- **Falsos negativos:** el riesgo más grave es que el modelo le diga a un paciente enfermo que está sano. En nuestras pruebas esto pasó con 6 de 28 enfermos, y en proporción les pasó más a las mujeres.
- **Confianza excesiva:** un resultado de "sin enfermedad" con una probabilidad baja puede dar una falsa sensación de seguridad, tanto al paciente como al personal de salud.
- **Uso fuera de contexto:** si el modelo se aplicara a una población muy distinta a la de los datos de entrenamiento, sus resultados podrían ser mucho peores sin que nadie lo note.

6.3 Limitaciones

- **Pocos datos:** 297 pacientes es muy poco para un problema médico, y el conjunto de prueba (60 pacientes) es pequeño para sacar conclusiones fuertes, sobre todo por grupos.
- **Población poco representativa:** los datos vienen de un solo hospital de Estados Unidos y se recolectaron hace más de 35 años. No sabemos si el modelo serviría para pacientes colombianos de hoy, con otras características, hábitos y acceso a la salud.
- **Variables limitadas:** el dataset no incluye factores que también influyen en la enfermedad cardíaca, como el tabaquismo, los antecedentes familiares o las condiciones socioeconómicas.
- **Simplificación del problema:** convertimos la gravedad de la enfermedad (de 0 a 4) en un simple sí o no, y algunas variables categóricas se trataron como numéricas.

6.4 Consideraciones éticas

Equidad. Un sistema de apoyo al diagnóstico debería funcionar igual de bien para todos los pacientes. Con los resultados actuales no podemos garantizarlo para las mujeres, así que antes de pensar en cualquier uso real habría que reentrenar el modelo con datos más equilibrados y volver a evaluarlo por grupos.

Privacidad. Los datos de salud son de los más sensibles que existen. El dataset que usamos es público y no tiene nombres ni documentos de identidad, así que no expone a personas concretas. Pero si un modelo así se entrenara con historias clínicas reales en Colombia, habría que cumplir la Ley 1581 de 2012 de protección de datos personales, que clasifica los datos de salud como datos sensibles y exige, entre otras cosas, la autorización explícita de los pacientes.

Impacto social. Si un hospital usara este modelo para decidir a quién atender primero, sus errores tendrían consecuencias reales: personas enfermas podrían quedar al final de la fila. Y si el modelo falla más con un grupo, como las mujeres, podría aumentar desigualdades que ya existen en la atención en salud.

Justicia y transparencia. Una ventaja de la Regresión Logística es que se puede explicar: sabemos qué variables pesan más y en qué dirección. Esto permite que un médico revise la predicción, la cuestione y

entienda de dónde viene. En un problema de salud, preferimos un modelo un poco menos preciso pero explicable a uno más preciso que funcione como una caja negra.

Uso responsable. Por todo lo anterior, consideramos que este modelo solo debe usarse con fines académicos o, en el mejor de los casos, como una herramienta de apoyo que siempre pase por la revisión de un profesional de la salud. Nunca debería tomar decisiones por sí solo, y cualquier persona que lo use debería conocer sus limitaciones, especialmente su menor desempeño con las mujeres.

7. Conclusiones técnicas

El modelo funciona razonablemente bien para lo simple que es. Con un Accuracy de 0.833 y un F1-Score de 0.815, la Regresión Logística supera claramente al modelo de referencia y demuestra que las variables clínicas del dataset sí permiten anticipar la enfermedad cardíaca.

Su punto débil es el Recall. Con 0.786, no alcanzó el 0.80 que nos propusimos, y dejó sin detectar a 6 de los 28 pacientes enfermos. En un problema médico, este es el aspecto que más hay que mejorar.

El desempeño no es igual para todos. El modelo detecta peor la enfermedad en las mujeres (Recall de 0.667 frente a 0.800 en los hombres). Aunque la muestra es pequeña, el resultado coincide con el desequilibrio que ya mostraban los datos.

Las variables más influyentes tienen sentido clínico. El número de vasos coloreados (ca), la talasemia (thal) y el tipo de dolor de pecho (cp) son las que más pesan, lo cual da cierta confianza en que el modelo aprende relaciones razonables y no solo ruido.

El proceso es reproducible. Todo el flujo, desde la carga de los datos hasta la predicción, se puede repetir con los scripts del repositorio y da los mismos resultados.

8. Recomendaciones de mejora

1. Ajustar el umbral de decisión**:** Hoy el modelo clasifica como enfermo a quien supera una probabilidad de 0.5. Bajar ese umbral haría que detectara más enfermos (más Recall), a cambio de algunas falsas alarmas más, que en este contexto es un intercambio aceptable.
2. Conseguir más datos y más diversos: Sobre todo más mujeres, y en lo posible datos de población colombiana o latinoamericana, para que el modelo sea más justo y más útil en nuestro contexto.
3. Tratar correctamente las variables categóricas: Variables como `cp`, `thal` y `slope` son categorías, no números. Codificarlas con *one-hot encoding* podría mejorar el modelo.
4. Usar validación cruzada: En lugar de una sola división 80/20, evaluar el modelo en varias particiones daría métricas más confiables con tan pocos datos.
5. Probar otros modelos: Comparar con un Árbol de Decisión o un Random Forest, siempre sin perder de vista la interpretabilidad.
6. Evaluar la equidad de forma permanente: Cualquier versión nueva del modelo debería revisarse por sexo, y también por otros grupos como la edad, antes de considerarse aceptable.

9. Referencias

- Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). *Heart Disease* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61.
- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90-95.
- Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
- Amazon Web Services. *Create an Amazon SageMaker notebook instance*. https://docs.aws.amazon.com/sagemaker/latest/dg/howitworks-create-ws.html
- Congreso de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*.